第九届传智杯 AI WEB 网页开发挑战赛 · 技术说明文档

制造领航 ForgePilot

面向中小制造企业的设备维护 AI 工作台

设备台账 · 证据检索 · AI 辅助诊断 · 人工确认 · 工单闭环 · 审计追踪



团队：梁晓添（产品 / 前端 / 集成 / 部署）· 林同学（业务后端 / 视频）· 龚同学（知识检索与诊断）
指导教师：丁老师 ｜ 版本：v1.0 ｜ 日期：2026-10-31
在线演示：https://forgepilot.xiaotianworks.cn/ ｜ 代码仓库：https://github.com/lxiaotian685-web/forgepilot-ai

摘要

ForgePilot 把制造企业设备维护中分散的“设备档案、说明书知识、现场现象、维修任务、操作记录”收敛到一个 Web 工作台，用检索增强生成（RAG）与真实大模型给出**有证据、可核对、需人工确认**的诊断建议，再把建议转化为可跟踪的维修工单和审计记录。

6	3	1,904	2
演示设备	诊断证据来源	单次诊断 Token	云端服务

文档结构

1. 项目背景与需求 03
2. 总体架构 04
3. 数据模型与权限 05
4. AI 方案：RAG 与证据诊断 06
5. 人工在环与受控 Agent 07
6. 核心功能与界面 08
7. 诊断闭环实拍 09
8. 知识与审计 11
9. 关键实现 12
10. 测试与质量 13
11. 安全、数据与合规 14
12. 创新点与展望 15
附录：运行与账号 16

关键词

RAG DeepSeek 证据引用 结构化输出 Human-in-the-loop FastAPI React CloudBase

说明：本文档中的设备、告警、工单和说明书均为虚构演示数据；在线演示接入服务端真实 DeepSeek，结论仍需人工核验，不代表企业真实诊断结论。

1. 项目背景与需求

1.1 问题

信息分散

设备运行数据在监控系统，说明书在共享盘或个人电脑，维修任务在表格或聊天群里，三者无法互相对照。

经验依赖

现场判断依赖老师傅经验，新人难以快速定位“应该先查什么”，也难以说明依据。

过程不可追溯

诊断结论、谁确认、何时建单、改了哪些字段，缺少统一记录。

AI 不可信

直接让大模型给结论，容易出现无依据回答、引用错文档、把推断当事实。

1.2 目标

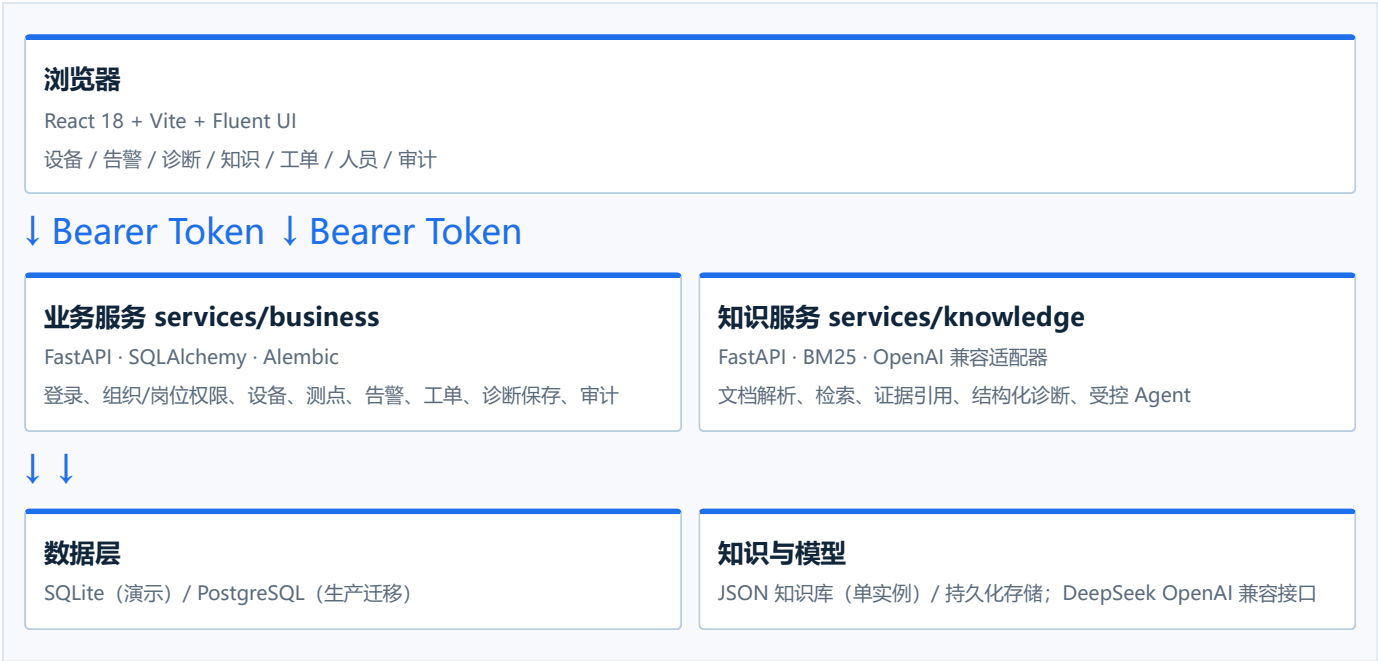
- 用一个工作台串起：设备查询 → 证据检索 → AI 辅助诊断 → 人工确认 → 生成工单 → 维修验收 → 审计追踪。
- AI 的每一个判断都能回到说明书原文；不能回到原文的内容必须明确标注为推断或待验证。
- 模型只提建议，保存诊断、确认风险、生成工单都由人触发，并且幂等、可审计。
- 首条验收路线固定为演示设备 **AC-07 螺杆空气压缩机**，不使用未标明的静态数据伪装真实接口。

1.3 非目标

- 不做设备远程控制，不自动执行停机、启机或参数下发。
- 不在没有授权数据时宣称企业真实诊断能力；当前全部为虚构演示数据。
- 不把系统做成通用聊天机器人，而是围绕设备维护流程的受控工作流。

对应比赛评分：AI 深度、创新、前端工程、实用性、用户体验、社会价值与商业潜力。

2. 总体架构



2.1 服务边界

服务	职责	不负责
前端	页面、交互、权限导航、证据阅读、调用两个 API	不持有模型密钥，不伪造接口数据
业务服务	身份与组织、设备事实、告警/工单状态机、诊断落库、审计	不调用大模型
知识服务	文档解析检索、模型调用、引用校验、结构化诊断、只读 Agent	不直接建单，不操作设备

2.2 关键设计

- 身份由业务服务签发 Bearer Token；知识服务每次请求回查业务服务确认身份，不信任客户端伪造组织头。
- 前端有 `mock | api` 两种数据模式；API 模式请求失败会明确报错，不回退成演示数据。
- 知识服务保持单实例 + 持久化卷；多实例前必须先改造知识库存储。

3. 数据模型与权限

3.1 核心对象

对象	关键字段	说明
Organization / Membership	id、code、role	组织隔离；角色 owner / admin / manager / technician / viewer
Device	device_id、model、plant、health、status	首条演示设备 AC-07
DeviceParameter	name、value、unit、threshold	设备专属测点，不同设备指标不同
Alert	code、level、status、owner	待确认 → 处理中 → 已关闭
WorkOrder	code、status、priority、owner、plan	列表 / 看板 / 日历；合法状态流转
Diagnosis	status、risk、model、tokens、sources	只有非模拟且证据校验通过才允许保存
AuditLog	actor、action、entity、before/after	诊断、建单、确认、人员变更均可追溯

3.2 权限与隔离

- 导航按岗位显示；维修人员只能处理本人告警/工单，主管负责验收与取消。
- 所有查询带组织条件；跨组织设备返回 403，不泄露是否存在。
- 人员停用前必须选择未完成工单接收人，转派写入审计。
- 知识文档上传、删除限制管理岗位，并校验组织归属。

3.3 幂等与事务

人工确认生成工单时，以诊断 ID 作为幂等键；重复确认返回同一张工单。保存诊断、确认、建单在同一事务边界内完成，失败整体回滚，避免“诊断已保存但工单只建了一半”。

实现位置：services/business/app/api、app/security.py；迁移见 services/business/alembic。

4. AI 方案：RAG 与证据诊断

1 解析	2 检索	3 组装	4 生成	5 校验
说明书文本抽取与分块	BM25 + 设备型号/组织过滤	问题 + 设备事实 + 证据片段	DeepSeek 结构化输出	引用回查 + 降级

4.1 为什么先检索再生成

设备维护是强证据场景。模型参数里的“常识”不能替代本厂说明书。ForgePilot 先检索与当前设备型号匹配的说明书片段，把原文和来源一并交给模型，要求它只基于给定证据回答；检索不到足够证据时直接返回“证据不足”，而不是编一个答案。

4.2 证据与引用

- 每条证据带文档标题、页码/片段、设备型号、组织、相似度分数。
- 模型输出必须引用证据 ID；服务端逐条校验引用是否存在于本次检索结果。
- 存在无效引用时整体降级：替换原回答与摘要，标记 `status=degraded`，前端不允许保存为正式诊断。
- 设备型号不一致时拒绝检索（`model_mismatch`），避免 AC-07 查到 CNC 手册。

4.3 结构化诊断

字段	含义	页面呈现
statements.fact	文档直接支持的内容	文档陈述
statements.inference	模型基于证据的推断	模型推断
statements.pending	仍需现场确认的内容	待验证项
conflicts	资料之间或资料与现场描述冲突	冲突提示
verificationSuggestions	建议补采的测点/工况	证据补采清单
model / tokens	模型名与输入/输出/合计 Token	结果顶部与诊断记录

5. 人工在环与受控 Agent

5.1 人机分工

模型负责

检索证据、归纳文档陈述、提出推断、列出待验证项、给出补采建议。

人负责

判断现场风险等级、决定是否采纳、保存诊断、确认生成工单、完成维修验收。

5.2 为什么不让模型直接建单

- 诊断错误会带来停机、备件和安全风险，必须有人承担确认责任。
- 模型无法知道现场是否已断电、是否具备备件、是否影响生产计划。
- 人工确认后建单，才能把“谁确认、依据哪些证据、何时建单”写进审计。

5.3 受控只读 Agent

`POST /api/v1/agent/assist` 执行固定白名单工具：设备查询 → 同设备历史工单 → 证据诊断。每一步返回状态（ok / unavailable）和数量，前端逐步展示；工具名、状态、数量写入业务服务审计，不发送提问原文或模型回答。Agent 不修改设备、不创建工单，也不能绕过人工确认。

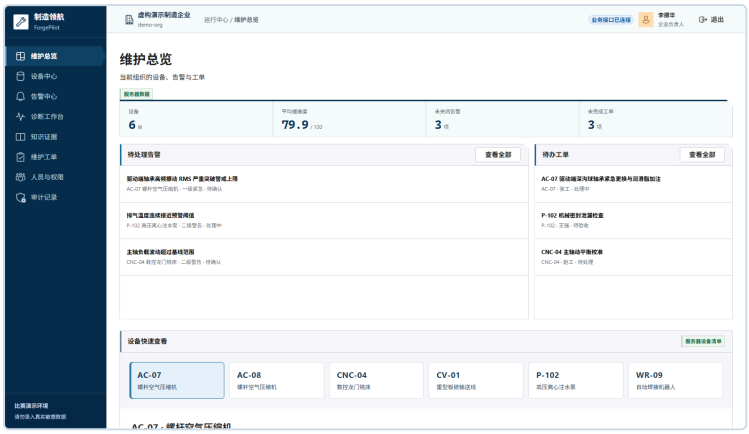
5.4 可观测性

诊断响应返回模型 provider、model、输入/输出/合计 Token；诊断保存时记录模型来源，便于在工单与审计中回溯“这条建议由哪个模型、消耗多少 Token 生成”。

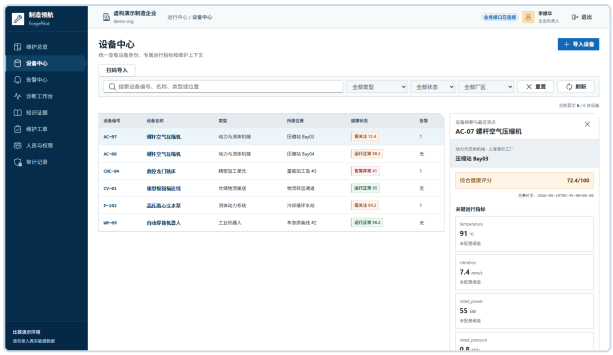
```
{
  "status": "ok",
  "is_mock": false,
  "model": "deepseek-flash",
  "input_tokens": 890,
  "output_tokens": 1014,
  "total_tokens": 1904,
  "sources": [ ... 3 条证据 ... ],
  "statements": [fact, inference, pending]
}
```

6. 核心功能与界面

6.1 维护总览与设备中心



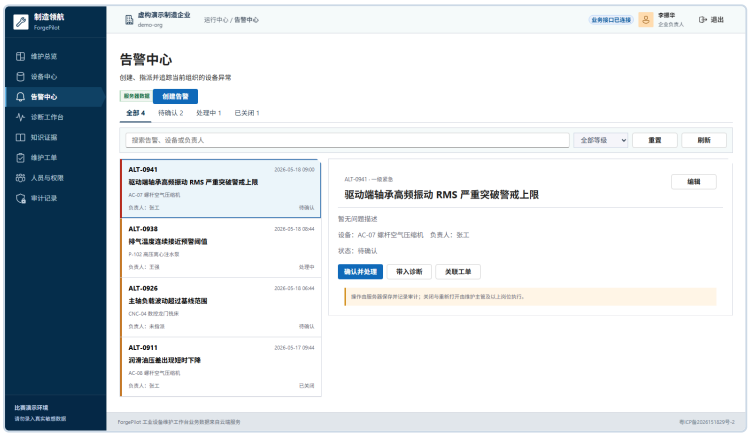
维护总览：健康度、告警、工单、最近诊断



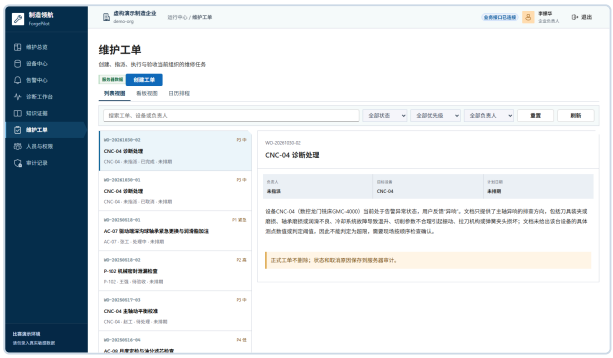
设备中心：专属测点、趋势与筛选

总览按当前组织实时聚合；不同设备使用不同指标，切换设备后测点、趋势、告警和资料摘要同步更新。设备导入支持 CSV 模板与扫码内容录入，扫描依赖浏览器 `BarcodeDetector`，同时提供手动粘贴。

6.2 告警与工单



告警中心：页签计数、组合筛选、指派与处理



维护工单：列表 / 看板 / 日历

告警区分待确认、处理中、已关闭；工单支持设备与负责人指派、优先级、计划时间、步骤勾选、提交验收、退回、完成和取消。草稿可删除，正式工单取消保留痕迹。

7. 诊断闭环实拍



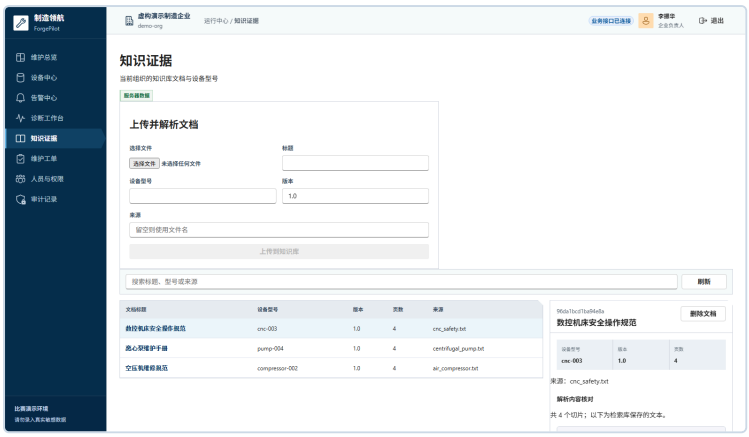
AC-07 真实 DeepSeek 诊断：文档陈述 3 条、模型推断 1 条、待验证 3 条、证据 3 条，Token 1,904

7.1 一次完整操作

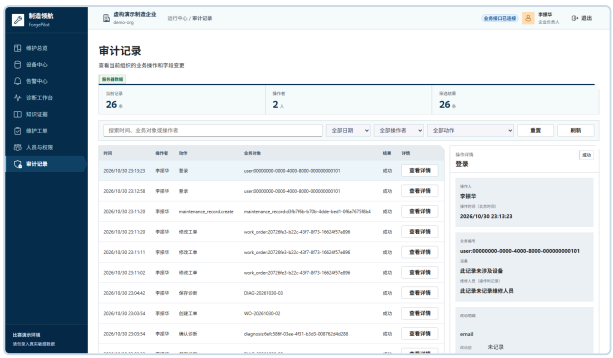
1. 从告警或设备页进入诊断工作台，目标设备自动带入 AC-07。
2. 输入现场描述：“运行一段时间后越来越烫，排气温度接近预警，应该先检查什么？”
3. 系统检索说明书证据，调用 DeepSeek，返回事实 / 推断 / 待验证三类内容。
4. 右侧证据阅读器逐条核对原文；冲突与补采建议单独展示。
5. 人工选择风险等级 → 保存诊断 → 确认生成工单，编号贯穿后续。
6. 在工单页指派、排期、推进状态；在审计页按编号追溯诊断与建单。

截图为线上演示环境实拍，模型信息、Token 用量和证据数量均来自真实接口响应。

8. 知识与审计



知识证据：上传、解析预览、检索引用



审计记录：操作人、对象、前后变更

8.1 知识管理

- 支持虚构说明书上传，服务端解析后返回文本预览；管理岗位可删除误上传文档。
- 文档按组织隔离，检索时同时按设备型号过滤，避免跨设备引用。
- 引用保留文档标题、片段、页码与相似度，前端可点击定位原文。

8.2 审计追踪

- 登录、告警处理、工单创建/编辑/验收/取消、诊断保存/确认、人员改岗与转派均写审计。
- 记录操作人、时间、对象类型与 ID、动作、前后字段变化。
- Agent 工具调用单独记录工具名、状态和数量，不记录提问原文与模型回答。

9. 关键实现

9.1 前端适配层

所有请求集中在 `frontend/src/services/api.js`：统一注入 Bearer Token、组织标识、错误码映射与超时；`mock` 与 `api` 两种模式共用页面组件，避免两套 UI。API 模式失败只提示错误，不回退演示数据。

9.2 身份与权限

业务服务用随机 `AUTH_SECRET` 签发 Token，解析后得到组织、用户、角色；知识服务通过 `C_IDENTITY_API_BASE_URL` 回查 `/api/v1/auth/me`，逐请求透传身份。生产环境缺少身份服务配置时拒绝启动，避免“裸奔”。

9.3 诊断保存与建单

只有 `is_mock=false` 且证据校验通过、状态为 `ok` 的诊断才允许保存；确认接口以诊断 ID 幂等，重复请求返回同一工单；建单与诊断状态更新在同一事务内，异常回滚。

9.4 云端部署

层	实现	说明
前端	CloudBase 静态托管 + 自定义域名	Vite 构建为 api 模式，API 地址只含公开地址
业务	CloudBase 云托管 forgepilot-business	容器启动自动种子数据；min=1 常驻
知识	CloudBase 云托管 forgepilot-knowledge	演示说明书随镜像打包；DeepSeek 密钥仅服务端环境变量
域名	forgepilot.xiaotianworks.cn	HTTPS + ICP 备案号页脚

9.5 关键取舍

- 选择 BM25 而非向量库：演示资料规模小、可解释、零额外基础设施；接口预留替换空间。
- 选择单进程 JSON 知识库：先保证可运行与可复现，明确标注多实例前必须迁移。
- 选择“证据不足就降级”：宁可少答，不把无依据内容包装成诊断。

10. 测试与质量

10.1 自动化测试

- 前端：纯函数、筛选、状态流转、权限导航、API 契约与空数据/401/403 场景。
- 业务服务：登录、组织隔离、设备、告警、工单状态机、诊断保存、幂等建单、事务回滚、审计。
- 知识服务：解析、检索、引用校验、无答案、无效引用降级、模型失败、Agent 工具状态。
- GitHub Actions：Frontend CI 与 Backend CI 在 `main` 上均为通过状态。

10.2 RAG 离线评测

指标	结果	说明
检索命中	16 / 16	问题能命中对应设备说明书片段
引用准确	16 / 16	回答引用均可在检索结果中找到
无答案识别	4 / 4	证据不足时明确返回 no_answer

10.3 真实模型验收

线上演示使用 `deepseek-flash` 完成 AC-07 诊断：返回 3 条证据、1,904 Token，页面显示模型名与用量；诊断保存、人工确认、幂等建单和审计查询均在同一环境实测通过。

10.4 仍需补强的测试

- 真实企业数据下的阈值与工况规则（当前只有演示测点，不自动断言超限）。
- 多实例知识库一致性、持久化存储故障恢复。
- 更大规模说明书集的检索质量与延迟。

11. 安全、数据与合规

11.1 数据边界

- 设备、告警、工单、说明书均为虚构演示数据，未使用未授权企业原始资料。
- 仓库只提交 `.env.example`；模型密钥、数据库口令、登录令牌不进入 Git。
- 企业数据接入前需确认授权主体、脱敏样例、使用范围（比赛/课程/GitHub/作品集）、保密与删除要求。

11.2 应用安全

- 身份由服务端解析，不信任客户端伪造组织/用户头。
- 模型密钥只在知识服务环境变量；前端仅配置公开 API 地址。
- CORS 限定自定义域名；生产环境要求 HTTPS、独立密钥与受控来源。
- Agent 白名单只读工具，落库与建单必须人工触发。

11.3 备案与页面标识

站点已完成 ICP 备案并在页脚展示备案号；公安联网备案按流程办理。演示页明确标注“虚构演示数据 / 请勿录入真实敏感信息”。

11.4 当前限制

- 云端容器使用 SQLite 与 JSON 知识库，重新部署或实例重启会恢复种子数据。
- 演示账号公开，仅用于评审与体验；不承载真实生产数据。
- 尚未接入企业真实传感器与阈值规则，不能宣称自动判定设备超限。

12. 创新点与展望

12.1 创新点

证据优先的诊断 UI

把“文档陈述 / 模型推断 / 待验证项”分栏呈现，AI 输出从一段话变成可核对的清单。

引用校验与整体降级

无效引用不是悄悄删掉，而是整体降级并禁止保存，避免“看起来完整”的错误诊断。

人工在环的建单闭环

模型建议不直接变成任务，风险分级与建单由人确认，并用幂等键保证重复操作安全。

可观测与可追溯

模型名、Token 用量、证据数量进入诊断记录与审计，能回答“这条建议怎么来的”。

12.2 展望

- 接入企业授权的设备手册与维修记录，建立按设备型号的阈值与工况规则。
- 知识库迁移到向量检索 + 持久化数据库，支持多实例与增量更新。
- 增加设备二维码扫码定位、移动端维修验收与离线草稿。
- 在受控范围内扩展 Agent 工具（备件库存、排班、工单优先级建议），继续坚持只读与人工确认。

12.3 结语

ForgePilot 不追求“让 AI 替人修设备”，而是让维护人员在每一步都能看到依据、做出判断、留下记录。对一个面向中小制造企业的作品来说，可信、可追溯、可落地，比模型参数更重要。

附录：运行、账号与仓库

A. 在线演示

项目	值
地址	https://forgepilot.xiaotianworks.cn/
账号	demo@example.com
密码	ForgePilot123!
组织代码	选填，留空
能力	真实登录、真实 DeepSeek 诊断、保存诊断、人工确认生成工单、审计查询

B. 本地运行

```
# Windows（Python 3.10+ / Node.js 20+ / PowerShell 7.4+）
.\scripts\quickstart.ps1
# 打开 http://127.0.0.1:5180/forgepilot/

# 使用真实 DeepSeek
$env:DEEPSEEK_API_KEY = "..."
.\scripts\start-demo.ps1 -DeepSeek
```

C. 仓库与文档

- 代码仓库：https://github.com/lxiaotian685-web/forgepilot-ai
- 部署说明：docs/CLOUDBASE_DEPLOY.md
- Linux 运行：docs/RUN_LINUX.md
- RAG 评测：services/knowledge/docs/real-rag-report.md
- 界面截图：docs/screenshots

D. 目录结构

```
frontend/                React + Vite + Fluent UI
services/business/       FastAPI 业务服务（登录、设备、告警、工单、审计）
services/knowledge/      FastAPI 知识服务（解析、检索、诊断、Agent）
docs/                    部署、数据库、截图与技术说明
scripts/                 本地启动、数据库准备、部署检查
```

© 2026 制造领航 ForgePilot 团队。本文档使用虚构演示数据；企业数据与真实模型输出均需人工核验。